


CODINGCAMP BY DBS FOUNDATION



LAPORAN TEKNIS PROYEK DATA SCIENCE



Analisis Prediktif Retensi Karyawan Menggunakan *Pipeline Machine Learning* Bebas Data *Leakage* pada Dataset IBM HR Attrition

Disusun Oleh	: Ananda Nashril Fikri Bachtiar Arya Ivan Ghally
Program Studi	: Informatika, Universitas Gunadarma
Tahun	: 2026

Disusun untuk Mendokumentasikan Hasil Proyek Capstone dalam Program
Coding Camp powered by DBS Foundation
Tahun 2026

BAB I. BUSINESS UNDERSTANDING

1.1 Latar Belakang

Sumber daya manusia merupakan aset penting bagi perusahaan karena berperan langsung dalam menjaga produktivitas dan keberlangsungan operasional. Tingginya tingkat pergantian karyawan (*employee attrition*) dapat menimbulkan berbagai dampak negatif, seperti meningkatnya biaya rekrutmen, proses pelatihan karyawan baru, penurunan produktivitas tim, serta hilangnya pengalaman dan pengetahuan yang telah dimiliki organisasi.

Oleh karena itu, perusahaan perlu memahami faktor-faktor yang memengaruhi keputusan karyawan untuk keluar dari perusahaan. Dengan memanfaatkan pendekatan data science, organisasi dapat mengidentifikasi pola attrition lebih awal dan menyusun strategi retensi yang lebih efektif.

1.2 Rumusan Masalah

- a) Faktor apa saja yang berkaitan dengan keputusan karyawan untuk mengundurkan diri?
- b) Bagaimana pola attrition jika ditinjau berdasarkan kombinasi tingkat pendapatan dan masa kerja karyawan?
- c) Bagaimana membangun pipeline data yang bebas dari data leakage dan siap digunakan untuk proses machine learning?

1.3 Tujuan Proyek

- a) Melakukan eksplorasi data untuk mengidentifikasi faktor-faktor yang berkaitan dengan attrition.
- b) Membangun pipeline pra-pemrosesan data yang mengikuti praktik machine learning yang baik dan bebas data leakage.
- c) Menghasilkan dataset yang siap digunakan pada tahap pemodelan machine learning maupun deep learning.

BAB II. DATA UNDERSTANDING DAN EXPLORATORY DATA ANALYSIS

2.1 Profil Dataset

Dataset yang digunakan adalah IBM HR Analytics Employee Attrition & Performance yang terdiri dari 1.470 data karyawan dengan 35 atribut yang mencakup informasi demografis, pekerjaan, kompensasi, kepuasan kerja, dan status attrition.

Hasil pemeriksaan kualitas data menunjukkan bahwa:

- a) Tidak terdapat nilai kosong (*missing values*).
- b) Tidak ditemukan data duplikat.
- c) Dataset memiliki beberapa kolom yang mengalami *Outlier* sangat banyak.

2.2 Hasil Exploratory Data Analysis

2.2.1 Pengaruh OverTime terhadap Attrition

Analisis tabulasi silang menunjukkan bahwa karyawan yang bekerja lembur memiliki tingkat attrition yang jauh lebih tinggi dibandingkan karyawan yang tidak lembur.

- a) Attrition pada kelompok yang melakukan lembur: 30,53%
- b) Attrition pada kelompok yang tidak melakukan lembur: 10,44%

Temuan ini menunjukkan bahwa beban kerja yang tinggi berpotensi meningkatkan risiko karyawan untuk meninggalkan perusahaan. Kondisi tersebut dapat berkaitan dengan kelelahan kerja (*burnout*) maupun ketidakseimbangan antara pekerjaan dan kehidupan pribadi.

2.2.2 Analisis Berdasarkan Pendapatan dan Masa Kerja

Segmentasi dilakukan menggunakan nilai median pendapatan bulanan dan median masa kerja di perusahaan.

Hasil analisis menunjukkan:

- a) Gaji rendah & masa kerja singkat: 28,85%
- b) Gaji tinggi & masa kerja singkat: 13,45%

c) Gaji rendah & masa kerja lama: 12,88%

d) Gaji tinggi & masa kerja lama: 9,57%

Kelompok dengan risiko attrition tertinggi adalah karyawan yang masih baru dan memiliki pendapatan di bawah median perusahaan. Sebaliknya, kelompok yang paling stabil adalah karyawan dengan masa kerja lebih lama dan pendapatan di atas median.

Temuan ini mengindikasikan bahwa fase awal masa kerja menjadi periode yang cukup krusial dalam mempertahankan karyawan.

2.2.3 Analisis Faktor Pendukung

Analisis tambahan dilakukan terhadap beberapa variabel lain yang berpotensi berkaitan dengan attrition, yaitu:

a) Environment Satisfaction

b) Job Satisfaction

c) Monthly Income

Hasil visualisasi menunjukkan kecenderungan bahwa tingkat kepuasan kerja yang lebih rendah serta pendapatan yang lebih kecil sering ditemukan pada kelompok karyawan yang mengalami attrition.

BAB III. DATA PREPARATION DAN PIPELINE MACHINE LEARNING

3.1 Feature Selection

Tahap awal dilakukan dengan menghapus fitur yang tidak memberikan informasi berarti atau berpotensi menimbulkan redundansi.

Fitur yang dihapus meliputi:

- a) EmployeeCount
- b) Over18
- c) StandardHours
- d) EmployeeNumber
- e) JobLevel
- f) PerformanceRating
- g) Department

Kolom-kolom tersebut dihapus karena bersifat konstan, hanya berfungsi sebagai identitas, atau memiliki informasi yang dianggap redundan terhadap fitur lain.

3.2 Feature Engineering

Sebelum membagi dataset, fitur-fitur turunan baru diekstraksi untuk menangkap konteks operasional HR yang tidak terlihat secara eksplisit pada data mentah. Pembuatan fitur di tahap ini dijamin bebas dari *Data Leakage* karena murni menggunakan operasi matematis baris-per-baris (*row-wise*), tanpa melibatkan agregasi atau nilai statistik populasi. Empat fitur baru dibuat untuk memperkaya informasi yang tersedia dalam dataset:

3.2.1 StagnationIndex

Mengukur selisih antara lama bekerja pada posisi saat ini dengan waktu sejak promosi terakhir.

3.2.2 OverallSatisfaction

Menggabungkan nilai:

- a) Environment Satisfaction
- b) Job Satisfaction
- c) Relationship Satisfaction

menjadi satu indikator kepuasan secara keseluruhan.

3.2.3 BurnoutFlag

Fitur biner yang menandai karyawan yang bekerja lembur dan memiliki jarak rumah ke kantor lebih dari 10 satuan.

3.2.4 YearsPerCompany

Menggambarkan rata-rata lama bekerja pada perusahaan sebelumnya berdasarkan total pengalaman kerja dan jumlah perusahaan yang pernah ditempati.

3.3 Train-Test Split

Dataset dipisahkan menjadi:

- a) 80% data latih
- b) 20% data uji

Pemisahan dilakukan menggunakan stratifikasi pada variabel target agar proporsi kelas attrition tetap terjaga pada kedua kelompok data.

3.4 Penanganan Outlier

Outlier pada fitur MonthlyIncome ditangani menggunakan metode Winsorizing berbasis IQR. Batas bawah dan batas atas dihitung hanya dari data latih, kemudian diterapkan pada data latih maupun data uji. Pendekatan ini menjaga agar informasi dari data uji tidak memengaruhi proses pelatihan.

3.5 One-Hot Encoding

Seluruh fitur kategorikal diubah menjadi representasi numerik menggunakan One-Hot Encoding dengan parameter `drop_first=True` untuk mengurangi redundansi fitur.

3.6 Feature Scaling

Standardisasi dilakukan menggunakan StandardScaler.

- a) Data latih menggunakan `fit_transform()`.
- b) Data uji hanya menggunakan `transform()`.

Dengan cara ini, parameter scaling dipelajari hanya dari data latih sehingga tidak terjadi kebocoran informasi.

3.7 Penanganan Ketidakseimbangan Kelas

Distribusi awal target Attrition menunjukkan ketidakseimbangan kelas yang cukup besar. Untuk mengatasinya digunakan metode SMOTE (*Synthetic Minority Over-sampling Technique*) pada data latih setelah proses scaling. Data uji tidak mengalami proses oversampling sehingga tetap merepresentasikan distribusi data sebenarnya.

BAB IV. HASIL AKHIR

4.1 Penyelarasan Data

Sebelum penggabungan kembali, indeks pada data uji diselaraskan menggunakan `reset_index()` untuk memastikan tidak terjadi ketidaksesuaian indeks yang dapat menghasilkan nilai kosong pada kolom target.

4.2 Dataset Siap Machine Learning

Data hasil SMOTE dan data uji kemudian digabungkan menjadi satu dataset akhir. Karakteristik dataset akhir:

- a) Jumlah baris: 2.456
- b) Jumlah kolom: 50
- c) Missing value pada target Attrition: 0

Dataset akhir telah berada dalam format numerik dan siap digunakan untuk berbagai algoritma machine learning maupun deep learning.

BAB V. KESIMPULAN DAN REKOMENDASI

5.1 Kesimpulan

Berdasarkan hasil analisis, faktor yang paling menonjol terkait attrition adalah lembur (*OverTime*). Karyawan yang bekerja lembur menunjukkan tingkat attrition hampir tiga kali lebih tinggi dibandingkan karyawan yang tidak lembur.

Selain itu, kelompok karyawan dengan masa kerja singkat dan pendapatan rendah memiliki risiko attrition tertinggi. Temuan ini menunjukkan pentingnya perhatian perusahaan terhadap fase awal karier karyawan.

Pipeline data yang dibangun juga telah mengikuti prinsip machine learning yang baik dengan menerapkan pemisahan data sejak awal proses dan menghindari data leakage pada seluruh tahapan transformasi.

5.2 Rekomendasi

5.2.1 Perspektif HR

- a) Mengurangi ketergantungan terhadap jam lembur yang berlebihan.
- b) Memperkuat program onboarding dan pendampingan pada tahun-tahun awal masa kerja.
- c) Memantau kelompok karyawan berisiko tinggi melalui indikator kepuasan kerja dan beban kerja.

5.2.2 Perspektif Machine Learning

- a) Mengutamakan metrik Recall dan F1-Score dibandingkan Accuracy karena distribusi kelas pada data uji tetap tidak seimbang.
- b) Memastikan jumlah fitur input pada model sesuai dengan jumlah fitur hasil preprocessing sebelum proses pelatihan dilakukan.